



Cadeias de Markov em árvores em redes de nós marcados

Cristiana Aparecida Nogueira Couto




cristianacouto@usp.br
Universidade de São Paulo

Orientador: Tiago Pereira


11 de maio de 2026



Cenário inicial de uma epidemia




Por fim, um cenário incompleto¹



¹BRITTON, T.; O'NEILL, P. D. Bayesian Inference for Stochastic Epidemics in Populations with Random Social Structure (2002).


Por fim, um cenário incompleto... que gostaríamos de completar




Qual pergunta gostaríamos de responder:

Dada uma *rede de contato* G e um conjunto de nós observados com seus respectivos tempos de infecção, nosso interesse é identificar quais nós não observados são mais prováveis de terem sido infectados.


Um caso trivial



Um caso trivial ... que pode ser complicado o quanto quisermos



Um caso trivial ... que pode ser complicado o quanto quisermos




Método

Ideia: Mapear o problema de encontrar os nós mais prováveis para um problema de amostragem e contagem em árvores. A frequência com que um nó aparece nas árvores amostradas estima sua probabilidade de infecção.






Modelo 1 (Modelo discreto SIR em redes)

Seja $G = (V, E)$ uma rede de contato para uma população arbitrária. Suponha que existe uma doença infecciosa que se espalha através das arestas de G como processo SIR em tempo discreto.


Modelo SIR



Propagação em uma rede de contato G



Status de um grafo



	a	b	c	d
t=1				
t=2				
t=3				


Dados parciais

Suponha que existem apenas informações parciais disponíveis, e o status de alguns indivíduos é desconhecido durante toda a epidemia. Podemos, então, dividir a população em dois conjuntos, um no qual o tempo de infecção é uma variável observada V_{obs} e outro não V_I . Logo,

$$V = V_{obs} \cup V_I,$$
$$D_{obs} = (t_i)_{i \in V_{obs}}.$$

onde D_{obs} é um vetor com os tempos de infecção observados para V_{obs} .

Dados parciais



	a	b	c	d
t=1	●		●	
t=2	●		●	
t=3	●		●	
t=4	●		●	


Conjunto de árvores de transmissão

Seja $\mathcal{T}$ o conjunto de todas as árvores de transmissão possíveis que descrevem um processo epidêmico descrito pelo Modelo 1 para uma rede de contato G :


$$\mathcal{T} = \{(V_T, E_T, \tau); V_T \subset V, E_T \subset E\} \quad (1)$$

Restrições em árvores


Os nós observados geram restrições sobre quais as possíveis árvores de transmissão.




Exemplo de árvores viáveis e não viáveis



Árvore I




Árvore II



Árvore III



Árvore IV



Perguntas:


Quais são os nós não-observados que mais provavelmente foram infectados? Qual a probabilidade de um nó não-observado ter sido infectado durante a epidemia?

Probabilidades para nós não observados


$$Pr(k \text{ infectado}) = \beta$$



$$Pr(i_n \text{ infectado}) = \beta^{n-1}$$




Árvores e nós infectados



$$\beta = \frac{1}{3}$$

$$Pr(T_1) = Pr(T_3) = Pr(T_5) = Pr(T_6) \approx 0.125$$


$$Pr(T_2) = Pr(T_4) \approx 0.25$$



$$\beta = \frac{1}{3}$$











$$Pr(T_1) = Pr(T_3) = Pr(T_5) = Pr(T_6) \approx 0.125$$











$$Pr(T_2) = Pr(T_4) \approx 0.25$$



$$Pr(1 \text{ infectado}) = Pr(3 \text{ infectado}) \approx 0.75$$

Amostragem de árvores





$$\hat{Pr}(T_1) = \hat{Pr}(T_3) = 0.1$$


$$\hat{Pr}(T_5) = \hat{Pr}(T_6) = 0.1$$

$$\hat{Pr}(T_2) = \hat{Pr}(T_4) = 0.3$$

$$\hat{Pr}(1 \text{ infectado}) = 0.7$$

$$\hat{Pr}(3 \text{ infectado}) = 0.7$$

Média espacial



$$\sum_{X_i \in S} \pi(X_i) f(X_i) = \sum_{T_i \in \mathcal{T}_f} Pr(T_i) 1_{v \in T_i}$$


Média espacial

$$\sum_{T_i \in \mathcal{T}_f} Pr(T_i) 1_{v \in T_i}$$

=

Média temporal

$$\frac{1}{N} \sum_{i=0}^{N-1} 1_{v \in X_i}$$



Princípio Fundamental: Teorema Ergódico para Cadeias de Markov²

$$\frac{1}{N} \sum_{i=0}^{N-1} \mathbf{1}_{v \in X_i} \xrightarrow{N \rightarrow \infty} \mathbb{E}_{\pi}[\mathbf{1}_{v \in T}] = Pr_{\pi}(v \in T) = Pr(v \text{ infectado}).$$

X_i é a árvore na iteração i da cadeia, e T é uma árvore aleatória distribuída de acordo com π .

²D. Levin, Y. Peres, and E. Wilmer. Markov chains and mixing times. American Mathematical Society, (2006)

Cadeias de Markov Monte Carlo

- Os métodos MCMC compõe uma classe de algoritmos para obter amostras de uma distribuição de probabilidade para qual uma amostragem direta é difícil.
- Para isso, uma cadeia de Markov é construída de forma que sua distribuição estacionária é a distribuição desejada.

Cadeias de Markov Monte Carlo

- Os métodos MCMC compõe uma classe de algoritmos para obter amostras de uma distribuição de probabilidade para qual uma amostragem direta é difícil.
- Para isso, uma cadeia de Markov é construída de forma que sua distribuição estacionária é a distribuição desejada.

Cadeia de Markov

Espaço de estados $\mathcal{T}_f = \{T_1, T_2, \dots, T_k\}$.

Dadas certas condições, o Teorema de Perron-Frobenius garante que uma distribuição π é estacionária para essa cadeia e é única.

Cadeias de Markov Monte Carlo

- Para garantir que a cadeia possui uma distribuição estacionária uma das condições necessárias é irredutibilidade.
- Para transitar entre os estados da cadeia precisamos definir operações que levem uma árvore $T_1 \in \mathcal{T}_f$ em $T_2 \in \mathcal{T}_f$.

Algoritmo de Metropolis-Hastings em um espaço de estados discreto

- 1 Primeiro, escolhe-se um estado arbitrário $i \in \mathcal{T}_f$ para X_0 . Inicializa-se uma matriz de transição Q associada a essa cadeia e define-se uma distribuição alvo $\pi = (\pi(1), \pi(2), \dots, \pi(k))$.

Algoritmo de Metropolis-Hastings em um espaço de estados discreto

- 1 Primeiro, escolhe-se um estado arbitrário $i \in \mathcal{T}_f$ para X_0 . Inicializa-se uma matriz de transição Q associada a essa cadeia e define-se uma distribuição alvo $\pi = (\pi(1), \pi(2), \dots, \pi(k))$.
- 2 Simule um valor $x_{prop} = j$ proposto a partir da matriz candidata Q .

Algoritmo de Metropolis-Hastings em um espaço de estados discreto

- 1 Primeiro, escolhe-se um estado arbitrário $i \in \mathcal{T}_f$ para X_0 . Inicializa-se uma matriz de transição Q associada a essa cadeia e define-se uma distribuição alvo $\pi = (\pi(1), \pi(2), \dots, \pi(k))$.
- 2 Simule um valor $x_{prop} = j$ proposto a partir da matriz candidata Q .
- 3 Calcule a probabilidade de aceitação para j :

$$\alpha_{ij} = \min \left(1, \frac{\pi(j)q_{ji}}{\pi(i)q_{ij}} \right)$$

Algoritmo de Metropolis-Hastings em um espaço de estados discreto

- 1 Primeiro, escolhe-se um estado arbitrário $i \in \mathcal{T}_f$ para X_0 . Inicializa-se uma matriz de transição Q associada a essa cadeia e define-se uma distribuição alvo $\pi = (\pi(1), \pi(2), \dots, \pi(k))$.
- 2 Simule um valor $x_{prop} = j$ proposto a partir da matriz candidata Q .
- 3 Calcule a probabilidade de aceitação para j :

$$\alpha_{ij} = \min \left(1, \frac{\pi(j)q_{ji}}{\pi(i)q_{ij}} \right)$$

- 4 Amostre $u \sim Unif[0, 1]$. Caso $u < \alpha_{ij}$, a transição é aceita e $X_{n+1} = j$, caso contrário, $X_{n+1} = X_n$.

Algoritmo de Metropolis-Hastings em um espaço de estados discreto

- 1 Primeiro, escolhe-se um estado arbitrário $i \in \mathcal{T}_f$ para X_0 . Inicializa-se uma matriz de transição Q associada a essa cadeia e define-se uma distribuição alvo $\pi = (\pi(1), \pi(2), \dots, \pi(k))$.
- 2 Simule um valor $x_{prop} = j$ proposto a partir da matriz candidata Q .
- 3 Calcule a probabilidade de aceitação para j :

$$\alpha_{ij} = \min \left(1, \frac{\pi(j)q_{ji}}{\pi(i)q_{ij}} \right)$$

- 4 Amostre $u \sim Unif[0, 1]$. Caso $u < \alpha_{ij}$, a transição é aceita e $X_{n+1} = j$, caso contrário, $X_{n+1} = X_n$.
- 5 Repita os passos 2 à 4 até que a convergência dessa cadeia seja atingida e uma amostra do tamanho desejado seja obtida.

Metropolis-Hastings em Grafos

Objetivo: simular de uma probabilidade π no conjunto $\mathcal{T}_f = \{T_1, \dots, T_k\}$.

Metropolis-Hastings em Grafos

Objetivo: simular de uma probabilidade π no conjunto $\mathcal{T}_f = \{T_1, \dots, T_k\}$.

- Tome $(X_n)_{n \in \mathbb{N}}$ uma cadeia de Markov com espaço de estados $\mathcal{T}_f$.

Metropolis-Hastings em Grafos

Objetivo: simular de uma probabilidade π no conjunto $\mathcal{T}_f = \{T_1, \dots, T_k\}$.

- Tome $(X_n)_{n \in \mathbb{N}}$ uma cadeia de Markov com espaço de estados $\mathcal{T}_f$.
- O kernel de transição é criado construindo um grafo conexo $G = (\mathcal{T}_f, E)$, onde d_i é o grau de um estado $i \in \mathcal{T}_f$ em G .

Metropolis-Hastings em Grafos

Objetivo: simular de uma probabilidade π no conjunto $\mathcal{T}_f = \{T_1, \dots, T_k\}$.

- Tome $(X_n)_{n \in \mathbb{N}}$ uma cadeia de Markov com espaço de estados $\mathcal{T}_f$.
- O kernel de transição é criado construindo um grafo conexo $G = (\mathcal{T}_f, E)$, onde d_i é o grau de um estado $i \in \mathcal{T}_f$ em G .
- Seja $X_n = i$, escolhemos um estado candidato j uniformemente do conjunto de estados adjacentes à i . Logo,

$$X_{n+1} = \begin{cases} j & \text{com probabilidade } \min\left(\frac{\pi(j)d_i}{\pi(i)d_j}, 1\right). \\ i & \text{com probabilidade } \left[1 - \min\left(\frac{\pi(j)d_i}{\pi(i)d_j}, 1\right)\right]. \end{cases}$$

Irredutibilidade

Se a cadeia definida pelas operações de adição e exclusão é irredutível, o Teorema de Perron-Frobenius garante convergência para π independentemente da árvore inicial.

Teorema de Perron-Frobenius e Prova via Métrica de Hilbert

O Teorema de Perron-Frobenius pode ser entendido como um caso particular do *Teorema do ponto fixo de Banach*, que afirma que se um mapa T é uma contração em um espaço métrico completo não vazio (X, d) , então T tem um ponto fixo único.

- $A : \mathbb{R}_+^d \rightarrow \mathbb{R}_+^d$ é um mapa linear positivo.
- Via Birkhoff (1957), A é uma contração com respeito à métrica de Hilbert d_H no espaço projetivo $\mathbf{P}(\mathbb{R}_+^d)$ de $\mathbb{R}_+^d$.
- O espaço $(\mathbf{P}(\mathbb{R}_+^d), d_H)$ é completo.
- Logo, existe um ponto fixo único para A em $\mathbf{P}(\mathbb{R}_+^d)$.

Teorema de Perron-Frobenius

Teorema (Perron-Frobenius para Matrizes Primitivas)

Seja P uma matriz de transição primitiva (irredutível e aperiódica) com distribuição estacionária π . Então, para qualquer distribuição inicial μ , temos que


$$\lim_{n \rightarrow \infty} \mu P^n = \pi,$$

e π é a única distribuição estacionária de P .


Cones

Seja E um espaço vetorial. Um subconjunto $C \in E \setminus \{0\}$ é um cone se C satisfaz que

$$v \in C \text{ e } t > 0 \Rightarrow tv \in C$$



Métrica de Hilbert



$$d_H(x, y) = \log \frac{\max_i (x_i / y_i)}{\min_i (x_i / y_i)}$$

$$\mathbf{P}(C) = \{[x]; x \in C \setminus \{0\}\} \text{ onde } y \in [x] \iff \exists \lambda > 0, x = \lambda y$$

$(\mathbf{P}(C), d_H)$ é um espaço métrico completo

Teorema

Seja $C \subset \mathbb{R}_+^d$ um cone convexo pontiagudo, d_H a métrica de Hilbert e $\mathbf{P}(C)$ o espaço projetivo do cone C . O espaço métrico dado por $(\mathbf{P}(C), d_H)$ é um espaço métrico completo.

Esboço da demonstração

Demonstração.

- Tome uma sequência de Cauchy $(\hat{x}_n)_n$ em C para d_H no simplex unitário.
- Via manipulações algébricas, obtemos

$$\|\hat{x}_n - \hat{x}_m\| = \sum_{k=1}^d |\hat{x}_{n,i} - \hat{x}_{m,i}| \leq d(e^\varepsilon - 1).$$

- Logo, $(\hat{x}_n)_n$ também é uma sequência de Cauchy para a norma $\|\cdot\|$. Uma vez que $\mathbb{R}^d$ é completo, a sequência $(\hat{x}_n)_n$ converge para algum $x \in \mathbb{R}^d$. Além disso,

$$\|x\| = \left\| \lim_{n \rightarrow \infty} \hat{x}_n \right\| = \lim_{n \rightarrow \infty} \|\hat{x}_n\| = 1.$$


- Por contradição, mostra-se que x não pode ter componentes nulas, logo $x \in \mathbf{P}(C)$.




Implementação do algoritmo

A partir daqui, descrevemos um algoritmo para o problema específico de amostrar do espaço de estado de árvores viáveis. Logo, começamos por definir as operações de **Adição** e **Exclusão** de um nó.

Operação de **Adição**



Operação de **exclusão**



Probabilidade de aceitação

Sejam T e T' duas árvores adjacentes. A probabilidade de aceitação para o MH é dada por


$$\alpha_{T,T'} = \min \left(1, \frac{Pr(T') q_T}{Pr(T) q_{T'}} \right) \quad (2)$$

Em particular, q_T é um valor determinado pelo grau de T , ou seja, quantas árvores estão à uma distância de uma operação de T .

Problema em aberto


Para garantir a convergência do algoritmo, precisamos mostrar que a cadeia é irredutível. Mostramos isso para casos específicos como no exemplo a seguir via operações de adição e exclusão, mas a prova para o caso geral permanece em aberto.

Exemplo - Caminho simples




Iterações	$\hat{Pr}(t_2 < \infty)$	$\hat{Pr}(t_3 < \infty)$	Taxa de aceitação	it/s
1000	0,282	0,085	36,30 %	9278,82
10000	0,306	0,093	39,79 %	7639,79
50000	0,297	0,089	38,77 %	8956,86

Metagrafo de árvores adjacentes



Convergência do algoritmo



Conclusões

- Aprendizados:
 - 1 Formulação do problema matemático.
 - 2 Teorema de Perron-Frobenius.
- Planos futuros: prova do caso geral.

Referências



Häggström O., (2002)

Finite Markov Chains and Algorithmic Applications

Cambridge University Press Online ISBN: 9780511613586 .



István Z. Kiss • Joel C. Miller • Péter L. Simon, (2017)

Mathematics of Epidemics on Networks From Exact to
Approximate Models

Springer Online ISBN: 978-3-319-50806-1 .



Pierre Brémaud (1999)

Markov Chains: Gibbs Fields, Monte Carlo Simulation and
Queues

Springer Online ISBN: 978-3-030-45982-6 .



Obrigada!

Apêndice A: Trabalhos Futuros

Para lidar com os problemas gerados pela operação de troca de caminhos, propomos outras ideias para transitar no espaço de árvores viáveis. Uma ideia é combinar múltiplos kernels de transição.

Lema

Assuma que $\{P_i\}_{i=1,\dots,p}$ são kernels de transição de Markov tais que cada P_i é π -invariante para qualquer $i \in \{1, \dots, p\}$, então o kernel da mistura

$$\sum_{i=1}^p \alpha_i P_i(x'|x)$$


é π -invariante para qualquer $\alpha_i \geq 0$, $\sum_{i=1}^p \alpha_i = 1$.

Mistura dependente de estados


Uma outra versão dessa mistura de kernels é dada pelo caso onde os coeficientes que acompanham os kernels de transição são dependentes do estado x onde a amostragem está atualmente.

Apêndice B: Encontrando árvores viáveis em um grafo G


Search for a 2-0 path of length $k = 4$:




$V_{obs} = \{0, 2\}$




Source node.




path length = 2




Backtrack and explore
a new edge out of 1.



Path length = 3
backtrack




All adjacent nodes of 4 have
been visited. There is
no way to reach 0.




Backtrack and explore
from edge (1,4).

We have found a 2-0
path of length $k = 4$.
The sequence
2-1-4-3-0



Apêndice C: Troca de caminhos



Exemplo: Grafo ciclo



Metagrafo de árvores adjacentes



Apêndice D: Uma prova via sistemas dinâmicos

Teorema (Teorema de Perron)

Seja A uma matriz primitiva com raio espectral λ . Então, λ é uma raiz simples do polinômio característico, a qual é estritamente maior do que o módulo de qualquer outra raiz. Além disso, λ possui autovetores estritamente positivos.

Esboço da demonstração


Demonstração.

A prova é dividida em três passos:

- Considere o simplex de probabilidade S . A matriz A induz um mapa contínuo φ que leva S nele mesmo. Pelo Teorema do ponto fixo de Brouwer, esse mapa possui um ponto fixo, o que mostra que A possui um autovetor não negativo. Dado que A é primitiva esse autovetor é estritamente positivo.
- Construa uma matriz P a partir de A de modo que P é estocástica.
- Por fim, mostre que 1 é uma raiz simples para o polinômio característico de P e é o raio espectral de P .





Apêndice E: Exemplo - Grafo estrela



Iterações	$\hat{Pr}(t_1 < \infty)$	$\hat{Pr}(t_3 < \infty)$	Taxa de aceitação	it/s
1000	0,294	0,278	59,20 %	8294,61
10000	0,289	0,307	59,74%	8215,15
50000	0,297	0,302	59,92 %	9277,08

Metagrafo de árvores adjacentes



Convergência do algoritmo

